IUT de Paris - Rives de Seine
Université Paris Cité

SAE ANALYSE DE DONNEES, REPORTING ET DATAVISUALISATION

FACTEURS DE MORTALITE EN SOINS INTENSIFS

Rapport technique informatique

Eda BASARAN

SOMMAIRE

Pages

1. Introduction.....3

2. Description des données brutes.....4

2.1 Origine et types de données.....4

2.2 Pourcentage de valeurs manquantes dans la base de données initiale.....4

3. Variables sélectionnées pour l'analyse de la base de données…….5

4. Création d'une base de données propre à partir des données brutes……..……..6 à 8

4.1 Préparation de l'environnement de travail et chargement des données.....6

4.2 Explication du code sur la sélection des variables.....7

4.3 Evaluation, nettoyage et traitement des valeurs manquantes et aberrantes……...7 et 8

+ ***ANALYSE UNIVARIEE DE LA VARIABLE PRINCIPALE*……..……..9**

5. Conclusion……..…..……..……10

ANNEXE : Description / Documentation programme réalisé pour création de base de données……..……...……..…..11 à 13

a. Code R complet avec commentaires.....11

b. Caractéristiques de la base de données principale.....12

c. Caractéristiques de la base de données après le premier nettoyage.....13

d. Résumé de la base de données après le second nettoyage.....13

e. Aperçu de la base de données finale.....13

1. INTRODUCTION

La mortalité en soins intensifs est un enjeu majeur pour la gestion des patients gravement malades. Comprendre les facteurs qui influencent le risque de décès dans ces services est essentiel pour améliorer la qualité des soins, ajuster les traitements et cibler les interventions de manière plus précise. Pour cela, il est nécessaire de prendre en compte un large éventail de caractéristiques des patients, comme leur âge, leurs antécédents médicaux, leur état physiologique au moment de l'admission, et même leurs conditions sociodémographiques. Dans ce cadre, une étude multicentrique, portant sur 5 500 patients adultes admis entre juin 1989 et janvier 1994 dans cinq centres hospitaliers aux États-Unis, cherche à explorer comment ces différents facteurs peuvent influencer la mortalité en soins intensifs.

Avant de pouvoir analyser ces données en profondeur, il est crucial de garantir leur qualité. Cela passe par un nettoyage minutieux des données : corriger les erreurs, gérer les valeurs manquantes, et organiser les informations pour qu'elles soient prêtes à être utilisées de manière fiable. Ce nettoyage est une étape clé avant toute analyse avancée. C'est pourquoi, dans cette étude, nous nous sommes concentrés en priorité sur cette phase préparatoire. Une fois les données nettoyées et organisées, nous serons en mesure de réaliser des analyses plus poussées pour mieux comprendre les relations entre les différents facteurs et la mortalité des patients.

L'objectif principal de cette analyse est de répondre à une question centrale : **Comment les éléments liés à l'état des patients déterminent-ils leur risque de mortalité en soins intensifs ?**

Cette question est cruciale, car identifier les facteurs influençant la mortalité en soins intensifs pourrait améliorer la prise en charge des patients et affiner les protocoles médicaux. Grâce à cette base de données riche, l'étude permet d'explorer les liens entre différents facteurs cliniques, physiologiques et sociodémographiques, et leur impact sur la survie des patients.

Hypothèses

Pour tenter de répondre à cette question, nous avons formulé plusieurs hypothèses, basées sur notre expérience clinique et les connaissances actuelles :

Tout d'abord, nous pensons que l'âge du patient influence le risque de mortalité. En effet, les patients plus âgés ont un risque de mortalité plus élevé que les plus jeunes. Ensuite, la gravité de l'état initial du patient est un facteur déterminant. Les patients souffrant de maladies chroniques (diabète, insuffisance rénale, pathologies cardiovasculaires) ont un risque plus élevé de décès.
Enfin, les paramètres physiologiques initiaux sont des prédicteurs de mortalité. Une pression artérielle basse, une fréquence cardiaque élevée, ou une saturation en oxygène faible sont des marqueurs de mauvais pronostic. Ces signes traduisent souvent une défaillance des organes vitaux

Pour tester ces hypothèses, nous avons commencé par une description détaillée des données brutes et des outils utilisés. Puis, nous avons effectué un nettoyage rigoureux de la base de données pour nous assurer de sa qualité. Enfin, nous avons réalisé une analyse univariée de la variable centrale afin de mieux comprendre les relations entre les différents facteurs et la mortalité en soins intensifs.

2. DESCRIPTION DES DONNÉES BRUTES

2.1 Origine et types de données brutes

Nous disposons de données réelles qui proviennent d'une étude observationnelle multicentrique réalisée entre juin 1989 et janvier 1994, impliquant 5 500 patients adultes (≥18 ans) admis en unité de soins intensifs (USI) dans cinq centres hospitaliers aux États-Unis. Cette étude a suivi ces patients pendant six mois pour collecter des données sur leur état de santé, leurs traitements et leur évolution.

Les données ont été collectées selon différentes méthodes en fonction des catégories de variables. Par exemple, les données sociodémographiques ont été recueillies via un questionnaire administré lors de l'admission en USI, tandis que les mesures cliniques ont été prises le jour suivant l'admission. Le jeu de données utilisé pour cette analyse provient du fichier **Epi_clin2024.txt**, qui contient des informations brutes recueillies dans le cadre de cette étude.

Le fichier **Epi_clin2024.txt** regroupe 67 variables classées en plusieurs catégories : diagnostics à l'admission, maladies associées, scores cliniques, caractéristiques physiologiques, événements, dates et informations sociodémographiques. Les types de données incluent des variables numériques (par exemple **l'âge : AGE**, le poids : **WTKILO1**, la tension artérielle : **MEANBP1**) et des variables textuelles (comme la catégorie principale de maladie :**CAT1**, la catégorie secondaire de maladie **CAT2**, le cancer : **CA**, etc.), permettant ainsi une analyse complète des différents facteurs de risque.

Afin de connaître la taille exacte du jeu de données, nous avons utilisé les fonctions **nrow(datafinal)** pour déterminer le nombre de lignes et **ncol(datafinal)** pour le nombre de colonnes. Le fichier contient ainsi 5 501 lignes et 67 colonnes.

2.2 Pourcentage de valeurs manquantes dans la base de données principale

Nous avons rencontré de nombreuses données manquantes et aberrantes dans la base de données principale, ce qui nuit à sa qualité globale. Environ **3,72 %** des données sont manquantes, ce qui peut impacter la précision de l'analyse. Des données aberrantes ont été identifiées, ce qui nécessite également une attention particulière dans le processus de nettoyage avant de pouvoir procéder à une analyse approfondie.

3. VARIABLES SELECTIONNEES POUR L'ANALYSE DE LA BASE DE DONNEES

Pour répondre à la problématique de l'étude, nous avons d'abord sélectionné notre **variable centrale**, DEATH, qui **représente le décès des patients durant le suivi**. Elle a été retenue pour l'analyse principale de notre sujet. Par la suite, nous avons sélectionné les critères pertinents liés à la mortalité des patients en soins intensifs. En tout, cela inclut 15 variables, ainsi que l'identifiant unique des patients (PTID). Ces critères sont les suivants :

- **Critères cliniques :** Nous avons sélectionné des variables liées :
  - au **diagnostic à l'admission** (`CARD` : cardiovasculaire, `SEPS` : Infectieux), afin de déterminer l'origine des pathologies des patients et évaluer si certains diagnostics augmentent le risque de mortalité en soins intensifs ;
  - aux **maladies associées (**`CHRPULHX` : Atteinte pulmonaire, `RENALHX` : Atteinte rénale, `IMMUNHX` : Immunosuppression/ VIH/ Diabète), car ces problèmes de santé supplémentaires peuvent aggraver l'état général des patients et influencer leur réponse au traitement, affectant ainsi leur risque de décès ;
  - aux **scores cliniques (**`SURV2MD1` : Probabilité estimée de survie à 2 mois, `APS1` : Score Apache 3, `SCOMA1` : Score Glasgow), qui permettent d'évaluer de manière objective l'état clinique global des patients et d'estimer leur risque de mortalité en soins intensifs. Cependant, la variable `ADLD3P` (évaluant les capacités des patients dans les activités quotidiennes) a été exclue, car elle contenait 4113 valeurs manquantes, par conséquent elle est inexploitable.
- **Critères physiologiques** : Les variables choisies incluent des **paramètres vitaux** et **biologiques** comme le **poids** (`WTKILO1`), la **tension artérielle** (`MEANBP1`), la **fréquence respiratoire** (`RESP1`) et **cardiaque** (`HRT1`), ainsi que **les leucocytes** (`WBLC1`), pour évaluer les globules blancs qui jouent un rôle essentiel dans la défense immunitaire de l'organisme. Ces variables sont essentielles pour l'évaluation des risques et de l'état de santé des patients.
- **Critères sociodémographiques** : L'âge a été conservé comme critère sociodémographique, car il est essentiel dans l'évaluation de la vulnérabilité et des risques associés aux pathologies.

4. CRÉATION D'UNE BASE DE DONNÉES PROPRE À PARTIR DES DONNÉES BRUTES ET DESCRIPTION DU SCRIPT R

Nous avons développé un programme en R sur le logiciel RStudio, dont l'objectif est de charger et nettoyer le jeu de données pour créer une base de données propre à l'analyse. Cette partie détaillera les différentes étapes du script, la méthodologie employée, et les analyses réalisées sur les données manquantes et aberrantes. Le script se divise en plusieurs parties, chacune correspondant à une phase du traitement des données. *(Annexe a)*

4.1 Préparation de l'environnement de travail et chargement des données *(Annexe a – ligne 1 à 17 du code)*

• Le script commence par nettoyer l'environnement de travail avec `rm(list=ls())`, ce qui supprime toutes les variables et objets en mémoire. Cela évite toute interférence avec des éléments précédents et assure un espace de travail vierge.
• Des librairies nécessaires sont chargées pour l'analyse des données. Ces librairies comprennent :
- **readr** : Utilisée pour charger des fichiers de données externes, comme des fichiers texte ou CSV, dans l'environnement R.
- **dply**r : Fournit des fonctions puissantes pour manipuler et transformer les données de manière fluide et efficace.

- **skimr** : Permet d'obtenir un résumé rapide des données, facilitant l'exploration des variables et leur type.

- **ggplot2** : Utilisée pour créer des visualisations graphiques avancées et esthétiques des données.

L'environnement et les outils nécessaires sont alors en place pour traiter les données.
• Une fois les librairies chargées, le script définit un répertoire de travail spécifique :

```
setwd("C:/Users/ACER/Desktop/BUT1/SAE/SAE Projet")
```

Cela permet de pointer vers un dossier spécifique sur l'ordinateur de l'utilisateur où les fichiers de données sont stockés. En définissant ce répertoire, le script sait exactement où chercher les fichiers à charger. Le jeu de données est ensuite importé avec la fonction `read.table`, qui charge le fichier texte (`Epi_clin2024.txt`) dans une variable appelée `donnee`. Ce fichier contient des tabulations comme séparateurs de colonnes (`sep="\t"`). La première ligne du fichier est utilisée pour définir les noms des colonnes, et les chaînes de caractères ne sont pas converties en facteurs (`stringsAsFactors=FALSE`). Si des valeurs sont manquantes dans certaines lignes, elles sont automatiquement remplies par des « N/A » (`fill=TRUE`).

4.2 Explication du code sur la sélection des variables (*Annexe a – ligne 27 à 32 du code*)

Nous avons utilisé la fonction `select ()` de `dplyr` pour choisir des variables cliniques, physiologiques et sociodémographiques. Nous avons également utilisé la fonction `mutate` pour créer une nouvelle colonne avec la variable AGE arrondie à l'unité près.

4.3 Évaluation, nettoyage et traitement des valeurs manquantes et aberrantes

- **Évaluation des valeurs manquantes :**

D'abord, nous avons analysé le nombre de données manquantes de chaque colonne, donc pour chaque variable. Pour ce faire, nous avons appliqué la fonction `summary(donnee)`, cette fonction permet de faire un résumé de chaque colonne, en précisant le minimum, le maximum, le 1er et 3e quartile, la médiane, la moyenne et aussi le nombre de données manquantes. (*Annexe b*)
Ensuite, nous avons évalué la qualité du jeu de données en calculant le pourcentage de données manquantes. Un calcul basé sur le nombre total de valeurs et le nombre de valeurs manquantes dans le jeu de données a été alors effectué : *(Annexe a – ligne 21 à 25)*
Cette étape permet de comprendre non seulement la proportion de données manquantes, mais aussi d'identifier les éventuels problèmes qui nécessiteraient un nettoyage supplémentaire des données.

- **Nettoyage et traitement des valeurs manquantes et aberrantes**

Les valeurs **aberrantes** sont des données qui se situent bien en dehors des plages normales ou attendues pour chaque variable. Elles peuvent affecter les résultats d'analyse et fausser les conclusions si elles ne sont pas traitées correctement. Nous avons alors traité ces valeurs aberrantes pour chaque variable. Grâce à la fonction `summary(df)`, nous avons pu identifier ces valeurs *(Annexe c)*.

`MEANBP1` (tension artérielle moyenne), `RESP1` (fréquence respiratoire), `HRT1` (fréquence cardiaque), `WBLC1` (leucocytes), `APS1` (score Apache) et `SCOMA1` (score Glasgow) sont toutes des variables pour lesquelles des valeurs aberrantes ont été identifiées. Nous avons alors utilisé la fonction `mutate` pour modifier les variables existantes en remplaçant certaines valeurs aberrantes par la médiane de la variable correspondante. En effet, la **médiane** est utilisée pour remplacer les valeurs aberrantes car elle est moins sensible aux valeurs extrêmes. Le remplacement par la médiane assure alors que les données continuent de représenter la distribution de la variable sans être perturbées par des valeurs non représentatives ou des erreurs de saisie. Pour remplacer ces valeurs aberrantes, nous avons alors utilisé la condition `ifelse` *(Annexe a ligne 34 à 45 du code)*. Voici alors les conditions des valeurs attendues pour chaque variable :

- `MEANBP1` : Les tensions artérielles en soins intensifs doivent normalement se situer entre 40 et 180 mmHg. Si la valeur est en dehors de cette plage, elle est remplacée par la médiane de la variable.
- `RESP1` : La fréquence respiratoire doit normalement être comprise entre 5 et 50 respirations par minute. Les valeurs en dehors de cette plage sont considérées comme aberrantes.
- `HRT1` : La fréquence cardiaque est généralement comprise entre 40 et 180 battements par minute. Les valeurs inférieures à 40 ou supérieures à 180 sont considérées comme extrêmes.
- `WBLC1` : Le nombre de leucocytes devrait se situer entre 3 et 15 milliards de cellules par litre. Des valeurs en dehors de cette plage sont aussi considérées comme des anomalies.
- `APS1` : Un score Apache supérieur à 300 est rare et pourrait indiquer une erreur de saisie ou un cas extrême qui n'est pas représentatif de la population générale.
- `SCOMA1` : Un score Glasgow supérieur à 50 est anormalement élevé. Les valeurs au-dessus de ce seuil sont remplacées par la médiane.

Après avoir inspecté les données pour identifier les valeurs manquantes et aberrantes, nous avons recalculé le pourcentage de valeurs manquantes, qui s'élève à **0,75 %** *(Annexe a – ligne 49 à 53 du code).* Ce faible taux n'affectera pas nos futures analyses, car il n'a pas d'impact notable sur la représentativité de l'ensemble.

Nous avons alors procédé à un dernier nettoyage en supprimant les lignes contenant des valeurs manquantes : *`datafinal <- df[complete.cases(df), ]`*

La fonction `complete.cases()` permet d'identifier les lignes complètes, c'est-à-dire celles qui ne contiennent aucune valeur manquante. Les lignes contenant des valeurs manquantes sont ainsi exclues du jeu de données final. Cela garantit que les analyses statistiques ultérieures sont basées sur un jeu de données complet, sans aucune donnée manquante ni aberrante. *(Annexe d et e)*

ANALYSE UNIVARIEE DE LA VARIABLE PRINCIPALE DEATH :

Nous avons effectué une analyse univariée de notre variable principale, **DEATH**, qui présente deux modalités : "Yes" (décédé) et "No" (non décédé). Les résultats montrent que 34 % des patients en soins intensifs ont survécu, tandis que 66 % sont décédés. Cette distribution met en lumière l'ampleur de la mortalité en soins intensifs et souligne l'importance de comprendre les facteurs qui influencent ce taux élevé de décès afin d'améliorer la prise en charge des patients.

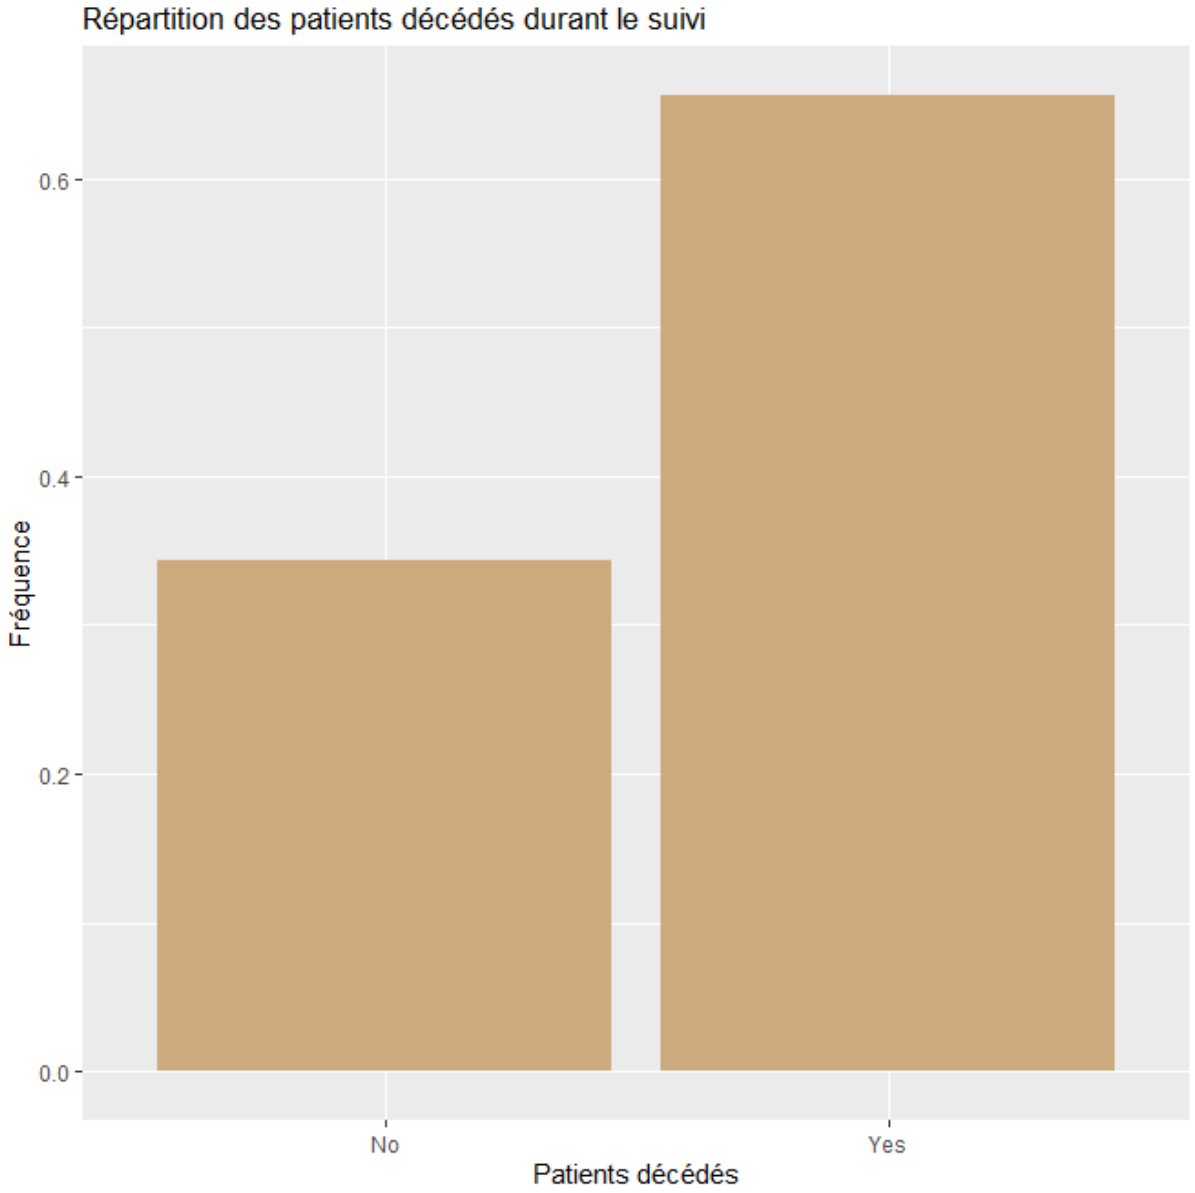

4.CONCLUSION

Pour conclure, l’analyse initiale des données a révélé la présence de valeurs manquantes et d'incohérences, ce qui a nécessité un nettoyage minutieux avant d'approfondir l’analyse. Avec RStudio, nous avons d'abord sélectionné les variables les plus pertinentes pour répondre à notre question sur la mortalité en soins intensifs, puis nous avons traité les valeurs manquantes et corrigé les erreurs dans les données.

Ce travail de préparation nous a permis de conserver 4851 observations sur un total de 5501, garantissant ainsi une base de données fiable pour explorer les facteurs qui influencent la mortalité des patients. En choisissant les bonnes variables dès le départ, nous avons optimisé notre jeu de données pour les analyses futures.

Les étapes réalisées, telles que la sélection des variables, la gestion des valeurs manquantes et la correction des valeurs aberrantes, sont cruciales avant de passer à des analyses plus complexes. Elles assurent la qualité et la pertinence des résultats à venir.

La prochaine étape consistera à effectuer des analyses statistiques approfondies, d'abord univariées et bivariées, suivies d'une approche exploratoire, pour identifier les facteurs les plus influents sur la mortalité en soins intensifs. Cela nous permettra de mieux comprendre les liens entre les caractéristiques des patients et leur risque de décès en soins intensifs.

Prise de recul :

En réfléchissant sur ce projet, nous pouvons dire que la sélection des variables était bien adaptée à notre question sur la mortalité en soins intensifs. Cependant, l’analyse a été compliquée par l’utilisation de termes cliniques que nous n’avions pas l’habitude de rencontrer, ce qui a nécessité un effort supplémentaire pour bien comprendre ces concepts. Cela nous a permis d’enrichir nos compétences dans l’analyse de données médicales.

De plus, le traitement des valeurs aberrantes reste un point à surveiller. Certaines de ces valeurs étaient difficiles à interpréter et nous n’étions pas toujours sûrs de la meilleure façon de les corriger. Il pourrait être nécessaire de revenir dessus pour s'assurer qu'elles n'affectent pas les résultats de manière négative.

ANNEXES : Description / Documentation programme réalisé pour création de base de données

a. Code R complet avec commentaires

```r
#vider le contenu de la mémoire
rm(list=ls())

#charger les librairies
.libPaths(c("C:/Users/ACER/Desktop/BUT1/R/Packages", .libPaths()))
library(readr)
library(dplyr)
library(skimr)
library(ggplot2)

#changement du repertoire courant
setwd("C:/Users/ACER/Desktop/BUT1/SAE/SAE Projet")

#charger les donnees
donnee <- read.table(file = "Epi_clin2024.txt", sep="\t", header = TRUE, stringsAsFactors=FALSE,
                     fill=TRUE, row.names= NULL)
View(donnee)
#résumé ensemble de la premiere base de donnee
summary(donnee)

#Calculer le pourcentage total de données manquantes dans toute la base de données
nb_valeurs <- prod(dim(donnee)) #nombre total d'éléments (lignes * colonnes)
nb_manquantes <- sum(is.na(donnee)) #nombre total de valeurs manquantes
donnee_manquant <- (nb_manquantes / nb_valeurs) * 100
cat(round(donnee_manquant, 2), "%")

#Nettoyage 1 de la base de données, sélection des variables
df <- donnee %>%
  mutate(AGE = round(AGE, 0)) %>%
  select(PTID, DEATH, AGE, WTKILO1, MEANBP1, RESP1, HRT1,
         WBLC1, CARD, SEPS, CHRPULHX, RENALHX,
         IMMUNHX, SURV2MD1, APS1, SCOMA1)
summary(df)
# Remplacer les valeurs aberrantes par la médiane ou une plage raisonnable
df2 <- df %>%
  mutate(
    WTKILO1 = round(WTKILO1, 2),
    MEANBP1 = ifelse(MEANBP1 < 40 | MEANBP1 > 180, median(MEANBP1, na.rm = TRUE), MEANBP1),
    RESP1 = ifelse(RESP1 < 5 | RESP1 > 50, median(RESP1, na.rm = TRUE), RESP1),
    HRT1 = ifelse(HRT1 < 40 | HRT1 > 180, median(HRT1, na.rm = TRUE), HRT1),
    WBLC1 = round(ifelse(WBLC1 < 3 | WBLC1 > 15, median(WBLC1, na.rm = TRUE), WBLC1),2),
    APS1 = ifelse(APS1 > 300, median(APS1, na.rm = TRUE), APS1),
    SCOMA1 = ifelse(SCOMA1 > 50, median(SCOMA1, na.rm = TRUE), SCOMA1),
    SURV2MD1 = round(SURV2MD1, 2)
  )
View(df2)
summary(df2)

# Calculer le pourcentage total de données manquantes dans toute la base de données
nb_valeursdf2 <- prod(dim(df2)) # nombre total d'éléments (lignes * colonnes)
nb_manquantesdf2 <- sum(is.na(df2)) # nombre total de valeurs manquantes
nb_manquantdf2 <- (nb_manquantesdf2 / nb_valeursdf2) * 100
cat(round(nb_manquantdf2, 2), "%")

```

```r
.

#Nettoyage 2 de la base de données, suppression des valeurs manquantes
datafinal <- df2[complete.cases(df2), ]
View(datafinal)
summary(datafinal)
skim(datafinal)

#analyse univariée de DEATH
ggplot(data = datafinal, aes(x = factor(DEATH))) +
  geom_bar(aes(y = after_stat(prop), group = 1), fill = "burlywood3") +
  labs(title = "Répartition des patients décédés durant le suivi",
       x = "Patients décédés",
       y = "Fréquence")
```

b. Caractéristiques de la base de données principale

```
      PTID           CAT1               CAT2               CA                DEATH              CARDIOHX          CHFHX
 Min.   :    5   Length:5500        Length:5500        Length:5500        Length:5500        Min.   :0.0000   Min.   :0.0000
 1st Qu.: 2576   Class :character   Class :character   Class :character   Class :character   1st Qu.:0.0000   1st Qu.:0.0000
 Median : 5158   Mode  :character   Mode  :character   Mode  :character   Mode  :character   Median :0.0000   Median :0.0000
 Mean   : 5148                                                                               Mean   :0.1756   Mean   :0.1773
 3rd Qu.: 7695                                                                               3rd Qu.:0.0000   3rd Qu.:0.0000
 Max.   :10278                                                                               Max.   :1.0000   Max.   :1.0000

    DEMENTHX          PSYCHHX           CHRPULHX          RENALHX           LIVERHX         GIBLEDHX          MALIGHX           IMMUNHX
 Min.   :0.00000   Min.   :0.00000   Min.   :0.0000   Min.   :0.00000   Min.   :0.00   Min.   :0.00000   Min.   :0.0000   Min.   :0.0000
 1st Qu.:0.00000   1st Qu.:0.00000   1st Qu.:0.0000   1st Qu.:0.00000   1st Qu.:0.00   1st Qu.:0.00000   1st Qu.:0.0000   1st Qu.:0.0000
 Median :0.00000   Median :0.00000   Median :0.0000   Median :0.00000   Median :0.00   Median :0.00000   Median :0.0000   Median :0.0000
 Mean   :0.09891   Mean   :0.06691   Mean   :0.1885   Mean   :0.04418   Mean   :0.07   Mean   :0.03182   Mean   :0.2289   Mean   :0.2696
 3rd Qu.:0.00000   3rd Qu.:0.00000   3rd Qu.:0.0000   3rd Qu.:0.00000   3rd Qu.:0.00   3rd Qu.:0.00000   3rd Qu.:0.0000   3rd Qu.:1.0000
 Max.   :1.00000   Max.   :1.00000   Max.   :1.0000   Max.   :1.00000   Max.   :1.00   Max.   :1.00000   Max.   :1.0000   Max.   :1.0000

    TRANSHX           AMIHX              AGE             SEX                EDU           SURV2MD1         DAS2D3PC          APS1
 Min.   :0.0000   Min.   :0.00000   Min.   : 18.04   Length:5500        Min.   : 0.00   Min.   :0.0000   Min.   :11.00   Min.   :  3.00
 1st Qu.:0.0000   1st Qu.:0.00000   1st Qu.: 50.20   Class :character   1st Qu.:10.00   1st Qu.:0.4700   1st Qu.:16.39   1st Qu.: 41.00
 Median :0.0000   Median :0.00000   Median : 64.05   Mode  :character   Median :12.00   Median :0.6280   Median :19.91   Median : 54.00
 Mean   :0.1149   Mean   :0.03473   Mean   : 61.37                      Mean   :11.67   Mean   :0.5924   Mean   :20.83   Mean   : 59.07
 3rd Qu.:0.0000   3rd Qu.:0.00000   3rd Qu.: 73.82                      3rd Qu.:13.00   3rd Qu.:0.7440   3rd Qu.:23.91   3rd Qu.: 68.00
 Max.   :1.0000   Max.   :1.00000   Max.   :101.85                      Max.   :30.00   Max.   :0.9620   Max.   :49.00   Max.   :499.00

     SCOMA1          MEANBP1          WBLC1             HRT1            RESP1            TEMP1           PAFI1            ALB1
 Min.   :  0.00   Min.   :  0.00   Min.   :  0.000   Min.   :  0.0   Min.   :  0.00   Min.   :27.00   Min.   : 11.6   Min.   : 0.300
 1st Qu.:  0.00   1st Qu.: 50.00   1st Qu.:  8.299   1st Qu.: 97.0   1st Qu.: 14.00   1st Qu.:36.09   1st Qu.:134.0   1st Qu.: 2.600
 Median :  0.00   Median : 63.00   Median : 14.000   Median :124.0   Median : 30.00   Median :38.09   Median :202.8   Median : 3.500
 Mean   : 23.34   Mean   : 78.43   Mean   : 15.638   Mean   :115.3   Mean   : 28.15   Mean   :37.62   Mean   :222.2   Mean   : 3.096
 3rd Qu.: 41.00   3rd Qu.:115.00   3rd Qu.: 20.098   3rd Qu.:142.0   3rd Qu.: 38.00   3rd Qu.:39.00   3rd Qu.:316.0   3rd Qu.: 3.500
 Max.   :299.00   Max.   :259.00   Max.   :192.000   Max.   :250.0   Max.   :100.00   Max.   :43.00   Max.   :869.4   Max.   :29.000
                  NA's   :36       NA's   :50        NA's   :43      NA's   :39       NA's   :53      NA's   :46      NA's   :48
     HEMA1            BILI1             CREA1             SOD1             POT1            PACO21           PH1            SWANG1
 Min.   : 4.50   Min.   : 0.09999   Min.   : 0.09999   Min.   :101.0   Min.   : 1.100   Min.   :  1.00   Min.   :6.579   Length:5500
 1st Qu.:26.20   1st Qu.: 0.79993   1st Qu.: 1.00000   1st Qu.:132.0   1st Qu.: 3.400   1st Qu.: 31.00   1st Qu.:7.340   Class :character
 Median :30.00   Median : 1.00977   Median : 1.50000   Median :136.0   Median : 3.800   Median : 37.00   Median :7.400   Mode  :character
 Mean   :31.88   Mean   : 2.26800   Mean   : 2.13039   Mean   :136.8   Mean   : 4.066   Mean   : 38.75   Mean   :7.389
 3rd Qu.:36.30   3rd Qu.: 1.39990   3rd Qu.: 2.39990   3rd Qu.:142.0   3rd Qu.: 4.600   3rd Qu.: 42.00   3rd Qu.:7.460
 Max.   :66.19   Max.   :58.19531   Max.   :25.09766   Max.   :178.0   Max.   :11.898   Max.   :156.00   Max.   :7.770
 NA's   :52      NA's   :48         NA's   :54         NA's   :33      NA's   :52       NA's   :41       NA's   :42


    WTKILO1         NINSCLAS            RESP              CARD              NEURO             GASTR             RENAL
 Min.   : 19.50   Length:5500        Length:5500        Length:5500        Length:5500        Length:5500        Length:5500
 1st Qu.: 60.40   Class :character   Class :character   Class :character   Class :character   Class :character   Class :character
 Median : 72.10   Mode  :character   Mode  :character   Mode  :character   Mode  :character   Mode  :character   Mode  :character
 Mean   : 74.49
 3rd Qu.: 85.20
 Max.   :244.00
 NA's   :492
     META               HEMA               SEPS              TRAUMA             ORTHO              ADLD3P         URIN1
 Length:5500        Length:5500        Length:5500        Length:5500        Length:5500        Min.   :0.00   Min.   :   0
 Class :character   Class :character   Class :character   Class :character   Class :character   1st Qu.:0.00   1st Qu.:1107
 Mode  :character   Mode  :character   Mode  :character   Mode  :character   Mode  :character   Median :0.00   Median :1923
                                                                              Mean   :1.18   Mean   :2190
                                                                              3rd Qu.:2.00   3rd Qu.:2965
                                                                              Max.   :7.00   Max.   :9000
                                                                              NA's   :4113   NA's   :2916
     RACE              INCOME              suppr      d_SADMDTE        m_SADMDTE        y_SADMDTE       d_DSCHDTE        m_DSCHDTE
 Length:5500        Length:5500        Min.   :0   Min.   : 1.00   Min.   : 1.000   Min.   :1989   Min.   : 1.00   Min.   : 1.000
 Class :character   Class :character   1st Qu.:0   1st Qu.: 8.00   1st Qu.: 3.000   1st Qu.:1990   1st Qu.: 8.00   1st Qu.: 3.000
 Mode  :character   Mode  :character   Median :0   Median :15.00   Median : 6.000   Median :1992   Median :16.00   Median : 6.000
                                       Mean   :0   Mean   :15.34   Mean   : 6.151   Mean   :1991   Mean   :15.71   Mean   : 6.435
                                       3rd Qu.:0   3rd Qu.:23.00   3rd Qu.: 9.000   3rd Qu.:1993   3rd Qu.:23.00   3rd Qu.: 9.000
                                       Max.   :0   Max.   :31.00   Max.   :12.000   Max.   :1994   Max.   :31.00   Max.   :12.000
                                                                                                  NA's   :1       NA's   :1
  y_DSCHDTE       d_DTHDTE        m_DTHDTE         y_DTHDTE       d_LSTCTDTE       m_LSTCTDTE       y_LSTCTDTE
 Min.   :1989   Min.   : 1.00   Min.   : 1.000   Min.   :1989   Min.   : 1.00   Min.   : 1.000   Min.   :1989
 1st Qu.:1990   1st Qu.: 8.00   1st Qu.: 3.000   1st Qu.:1990   1st Qu.: 8.00   1st Qu.: 3.000   1st Qu.:1990
 Median :1992   Median :16.00   Median : 6.000   Median :1992   Median :16.00   Median : 6.000   Median :1992
 Mean   :1991   Mean   :15.64   Mean   : 6.413   Mean   :1992   Mean   :15.65   Mean   : 6.433   Mean   :1992
 3rd Qu.:1993   3rd Qu.:23.00   3rd Qu.: 9.000   3rd Qu.:1993   3rd Qu.:23.00   3rd Qu.:10.000   3rd Qu.:1993
 Max.   :1994   Max.   :31.00   Max.   :12.000   Max.   :1994   Max.   :31.00   Max.   :12.000   Max.   :1994
 NA's   :1      NA's   :1920    NA's   :1920     NA's   :1920
```

c. Caractéristiques de la base de données après le premier nettoyage

```
      PTID          DEATH               AGE            WTKILO1          MEANBP1           RESP1             HRT1           WBLC1
 Min.   :    5   Length:5500        Min.   : 18.00   Min.   : 19.50   Min.   :  0.00   Min.   :  0.00   Min.   :  0.0   Min.   :  0.000
 1st Qu.: 2576   Class :character   1st Qu.: 50.00   1st Qu.: 60.40   1st Qu.: 50.00   1st Qu.: 14.00   1st Qu.: 97.0   1st Qu.:  8.299
 Median : 5158   Mode  :character   Median : 64.00   Median : 72.10   Median : 63.00   Median : 30.00   Median :124.0   Median : 14.000
 Mean   : 5148                      Mean   : 61.37   Mean   : 74.49   Mean   : 78.43   Mean   : 28.15   Mean   :115.3   Mean   : 15.638
 3rd Qu.: 7695                      3rd Qu.: 74.00   3rd Qu.: 85.20   3rd Qu.:115.00   3rd Qu.: 38.00   3rd Qu.:142.0   3rd Qu.: 20.098
 Max.   :10278                      Max.   :102.00   Max.   :244.00   Max.   :259.00   Max.   :100.00   Max.   :250.0   Max.   :192.000
                                                     NA's   :492      NA's   :36       NA's   :39       NA's   :43      NA's   :50
     CARD               SEPS             CHRPULHX          RENALHX           IMMUNHX           SURV2MD1          APS1            SCOMA1
 Length:5500        Length:5500        Min.   :0.0000   Min.   :0.00000   Min.   :0.0000   Min.   :0.0000   Min.   :  3.00   Min.   :  0.00
 Class :character   Class :character   1st Qu.:0.0000   1st Qu.:0.00000   1st Qu.:0.0000   1st Qu.:0.4700   1st Qu.: 41.00   1st Qu.:  0.00
 Mode  :character   Mode  :character   Median :0.0000   Median :0.00000   Median :0.0000   Median :0.6280   Median : 54.00   Median :  0.00
                                       Mean   :0.1885   Mean   :0.04418   Mean   :0.2696   Mean   :0.5924   Mean   : 59.07   Mean   : 23.34
                                       3rd Qu.:0.0000   3rd Qu.:0.00000   3rd Qu.:1.0000   3rd Qu.:0.7440   3rd Qu.: 68.00   3rd Qu.: 41.00
                                       Max.   :1.0000   Max.   :1.00000   Max.   :1.0000   Max.   :0.9620   Max.   :499.00   Max.   :299.00
```

d. Résumé de la base de données après le second nettoyage

```
> skim(datafinal)
-- Data Summary ------------------------
                           Values
Name                       datafinal
Number of rows             4851
Number of columns          16
_______________________
Column type frequency:
  character                3
  numeric                  13
________________________
Group variables            None

-- Variable type: character ----------------------------------------------------------------------------------------------------
  skim_variable n_missing complete_rate min max empty n_unique whitespace
1 DEATH                 0             1   2   3     0        2          0
2 CARD                  0             1   2   3     0        2          0
3 SEPS                  0             1   2   3     0        2          0

-- Variable type: numeric ------------------------------------------------------------------------------------------------------
   skim_variable n_missing complete_rate      mean       sd   p0     p25     p50     p75    p100 hist
 1 PTID                  0             1 5133.     2981.     5   2546.   5121    7698   10278   <U+2587><U+2587><U+2587><U+2587><U+2587>
 2 AGE                   0             1   61.7      16.4   18     51      64      74     102   <U+2582><U+2585><U+2587><U+2587><U+2581>
 3 WTKILO1               0             1   74.4      20.6   19.5   60.3    72      85.2   209.  <U+2582><U+2587><U+2582><U+2581><U+2581>
 4 MEANBP1               0             1   79.2      34.8   40     52      63     113     180   <U+2587><U+2581><U+2582><U+2582><U+2581>
 5 RESP1                 0             1   28.1      11.7    5     21      30      36      50   <U+2585><U+2581><U+2587><U+2585><U+2582>
 6 HRT1                  0             1  118.       32.7   40    106     124     140     180   <U+2583><U+2582><U+2587><U+2587><U+2583>
 7 WBLC1                 0             1   11.9       3.16   3     10.2    14      14      15   <U+2581><U+2581><U+2581><U+2582><U+2587>
 8 CHRPULHX              0             1    0.192     0.394  0      0       0       0       1   <U+2587><U+2581><U+2581><U+2581><U+2582>
 9 RENALHX               0             1    0.0456    0.209  0      0       0       0       1   <U+2587><U+2581><U+2581><U+2581><U+2581>
10 IMMUNHX               0             1    0.278     0.448  0      0       0       1       1   <U+2587><U+2581><U+2581><U+2581><U+2583>
11 SURV2MD1              0             1    0.596     0.195  0      0.48    0.63    0.75    0.96 <U+2581><U+2582><U+2585><U+2587><U+2585>
12 APS1                  0             1   55.4      19.7    3     42      54      68     147   <U+2582><U+2587><U+2585><U+2581><U+2581>
13 SCOMA1                0             1    8.54     15.2    0      0       0       9      44   <U+2587><U+2581><U+2581><U+2581><U+2582>
```

e. Aperçu de la base de données finale

	PTID	DEATH	AGE	WTKILO1	MEANBP1	RESP1	HRT1	WBLC1	CARD	SEPS	CHRPULHX	RENALHX	IMMUNHX	SURV2MD1	APS1	SCOMA1
1	5	No	70	64.7	41	10	124	14.0	Yes	No	1	0	0	0.64	46	0
3	10	Yes	75	54.6	55	26	58	14.0	No	No	0	0	1	0.44	48	0
4	11	Yes	68	78.4	65	27	125	14.0	Yes	No	0	0	0	0.44	72	41
5	12	No	86	54.9	115	36	134	14.0	No	No	1	0	0	0.66	38	0
7	14	Yes	44	81.3	128	34	102	14.0	No	Yes	0	0	0	0.63	25	0
8	16	No	18	90.6	53	30	118	14.0	No	No	0	0	0	0.50	47	0
9	17	No	48	43.7	73	40	141	14.0	No	No	0	0	0	0.67	48	0
10	19	No	34	79.5	66	30	50	14.0	No	No	0	0	0	0.85	21	0
11	21	No	68	60.9	50	10	158	14.0	Yes	No	0	0	0	0.72	50	0
12	22	Yes	75	93.0	53	12	104	14.0	Yes	No	0	0	0	0.47	51	9
13	24	Yes	42	59.0	77	40	110	7.3	No	No	0	0	1	0.67	55	37
14	25	No	82	90.1	67	37	100	10.6	Yes	No	0	0	0	0.58	54	0
15	28	Yes	78	74.9	122	40	116	13.5	No	No	0	0	0	0.38	59	9
17	30	Yes	69	64.1	134	39	136	14.0	Yes	Yes	0	0	0	0.57	66	0
18	31	No	41	68.9	53	12	130	5.4	No	Yes	0	1	0	0.78	60	9
19	32	No	68	101.0	55	10	125	14.0	No	No	1	0	0	0.57	69	0
20	33	No	51	70.0	47	40	102	14.0	No	Yes	0	1	1	0.78	68	0
21	35	Yes	63	96.0	120	48	119	14.0	No	No	0	0	0	0.22	59	37
22	39	Yes	42	115.0	47	20	122	10.1	Yes	No	0	0	0	0.89	30	0
23	40	No	23	130.0	117	30	160	9.3	No	No	0	0	0	0.69	42	0
24	41	Yes	62	107.3	63	22	115	5.5	Yes	No	0	0	0	0.86	26	0
25	43	Yes	48	60.3	119	12	126	14.0	No	No	0	0	0	0.55	40	0
26	44	Yes	37	73.0	40	37	145	4.2	No	No	0	0	1	0.08	84	0
27	45	Yes	71	64.9	44	30	124	14.0	Yes	No	1	0	0	0.11	89	0