IUT de Paris - Rives de Seine
Université Paris Cité

SAE Description et Prévision de séries temporelles Fiche de mission : Epidémiologie

Données : varicelle25.csv

Eda BASARAN

Table des matières

INTRODUCTION 2
1. Description des données 3
1.1 Indicateur 3
1.2 Traitement des données 3
2. Analyse des données 4
2.1 Analyse de la tendance 4
2.2 Analyse de la saisonnalité et décomposition saisonniers 5
2.3 Désaisonnalisation et analyse des résidus 6
2.3.1 Série désaisonnalisée 6
2.3.2 Analyse des résidus 6
3. Prévisions du taux d'incidence de la varicelle 7
3.1 Prévision pour l'automne et l'hiver 7
3.1.1 Méthode polynomiale 7
3.1.2 Méthode HW 8
3.1.3 Méthode Sarma 9
3.2 Évaluation de la qualité des prévisions 10
SUMMARY 11
RÉPARTITION DES TACHES 11

INTRODUCTION

L'analyse des séries temporelles est un outil fondamental en épidémiologie pour suivre l'évolution des maladies et anticiper les pics d'incidence. Dans le cadre de la SAE Description et Prévisions de séries temporelles, nous nous appuyons sur les données du réseau Sentinelles, un système de surveillance en médecine générale et pédiatrie en France métropolitaine, coordonné par l'équipe SUMO de l'IPLESP. Ce réseau, crée en 1984, collecte et met à disposition des bases de données sur plusieurs indicateurs sanitaires, dont les syndromes grippaux, la varicelle et la diarrhée aiguë, permettant une veille sanitaire et la réalisation d'études épidémiologiques.

En tant que membre de l'équipe de statisticiens chargée d'analyser ces données, notre mission, à partir des données mises à disposition (fichier CSV « *varicelle25.csv* »), consiste à analyser l'évolution du taux d'incidence de la varicelle, en particulier son taux d'incidence pour 100 000 habitants (*inc100*). L'objectif est d'étudier le taux d'incidence pour 100 000 habitants (inc100) de la varicelle, d'en analyser la tendance et la saisonnalité, puis de proposer des prévisions pour le reste de l'automne et le prochain hiver à l'aide de plusieurs méthodes statistiques : tout cela dans le but d'apporter des éléments d'analyse utiles à la gestion sanitaire.

1. Description des données

1.1 Indicateur

Notre base de données issus du réseau Sentinelles s'étend sur une période de 35 ans, de 1990 (semaine 49) jusqu'en 2025 (semaine 40). Elle comporte 1818 observations hebdomadaires et 10 variables. Notre équipe va se concentrer sur le taux d'incidence de la varicelle pour 100 000 habitants. En épidémiologie, l'incidence d'une maladie est le nombre de nouveaux cas de cette maladie observés sur une période donnée. Le taux d'incidence est calculé en rapportant ce nombre de nouveaux cas (population incidente) à la taille de la population cible, toujours pendant une période donnée.

1.2 Traitement des données

Avant de commencer l'analyse des données, nous avons procédé à une vérification afin d'identifier la présence éventuelle de valeurs manquantes. Cette étape est essentielle pour garantir la fiabilité et la qualité des analyses statistiques à venir. Dans notre cas, cette vérification a montré qu'il n'y avait aucune valeur manquante dans le jeu de données, ce qui nous a permis de poursuivre l'analyse sans avoir recours à des méthodes de traitement ou de correction spécifiques.

Dans un second temps, nous avons transformé la variable *inc_100* en une série temporelle afin d'analyser son évolution dans le temps. La série temporelle ainsi obtenue a été nommée *inc_ts* et définie avec une fréquence de 52, correspondant à des données hebdomadaires. Elle a ensuite servi de base pour les analyses temporelles réalisées par la suite.

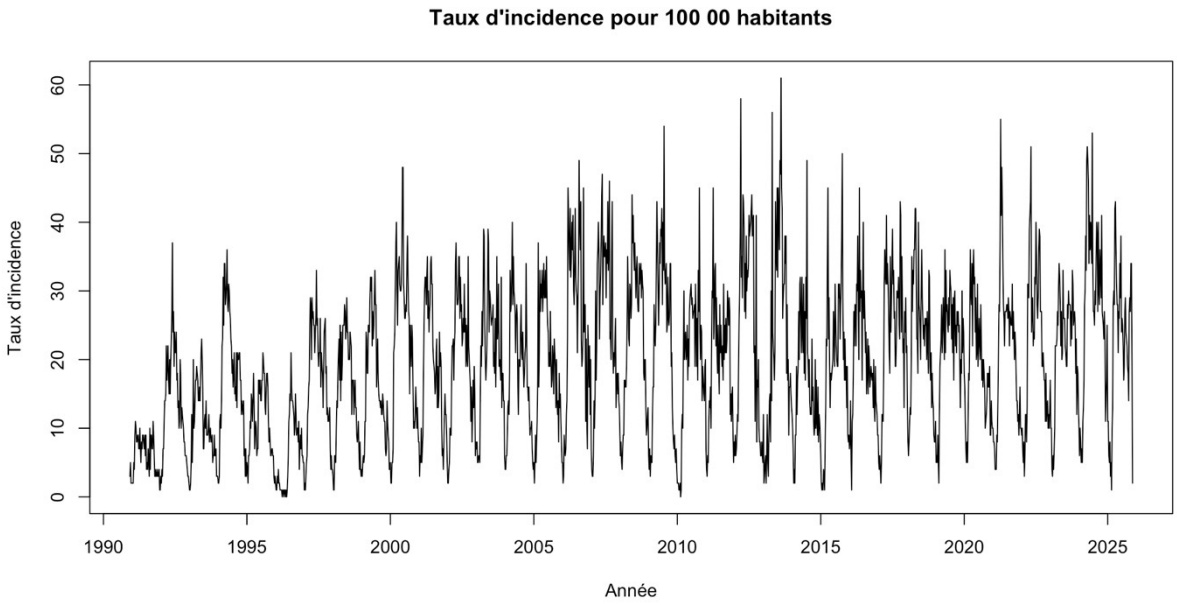

2. Analyse des données

2.1 Analyse de la tendance

Nous avons réalisé une estimation de la tendance de la série temporelle du taux d'incidence de la varicelle à l'aide d'un filtre de moyennes mobiles centrée.

La moyenne est calculée sur 52 semaines, soit une année complète, ce qui permet de lisser les variations à court terme et d'atténuer les effets saisonniers. Chaque valeur de la tendance est ainsi calculée comme la moyenne des 52 observations entourant le point considéré.

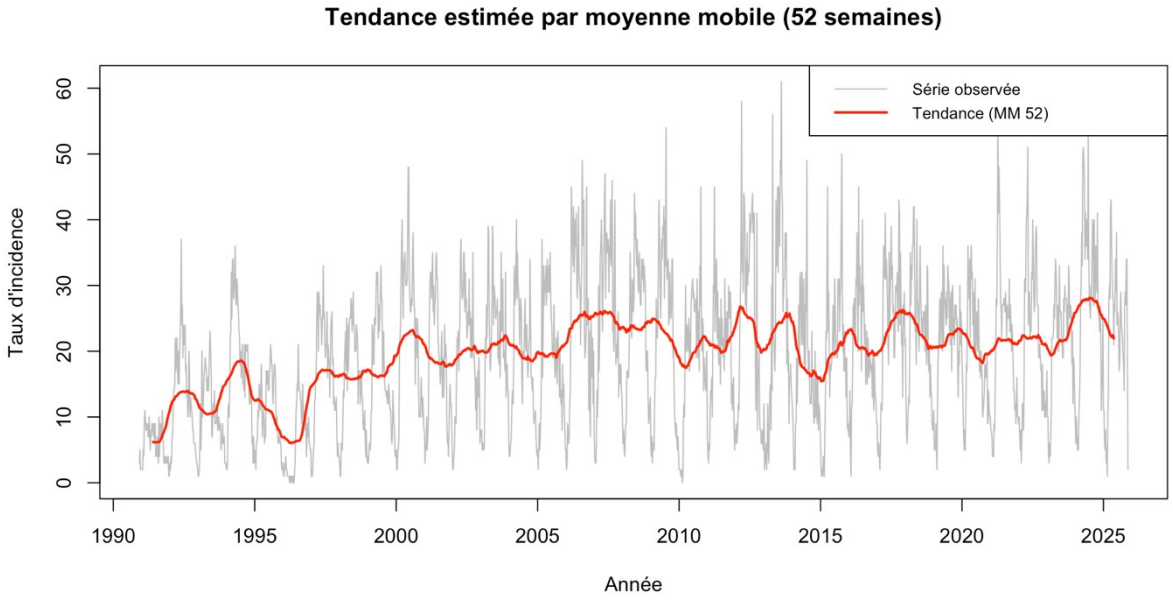

Le graphique obtenu montre une tendance globale marquée par des périodes de hausse et de baisse du taux d'incidence. Cela reflète l'impact probable de facteurs tels que les campagnes de vaccination, les variations démographiques ou les changements de pratiques médicales.

2.2 Analyse de la saisonnalité et décomposition saisonniers

Nous avons utilisé la fonction *decompose* pour fournir séparément la tendance, la saisonnalité et le résidu.

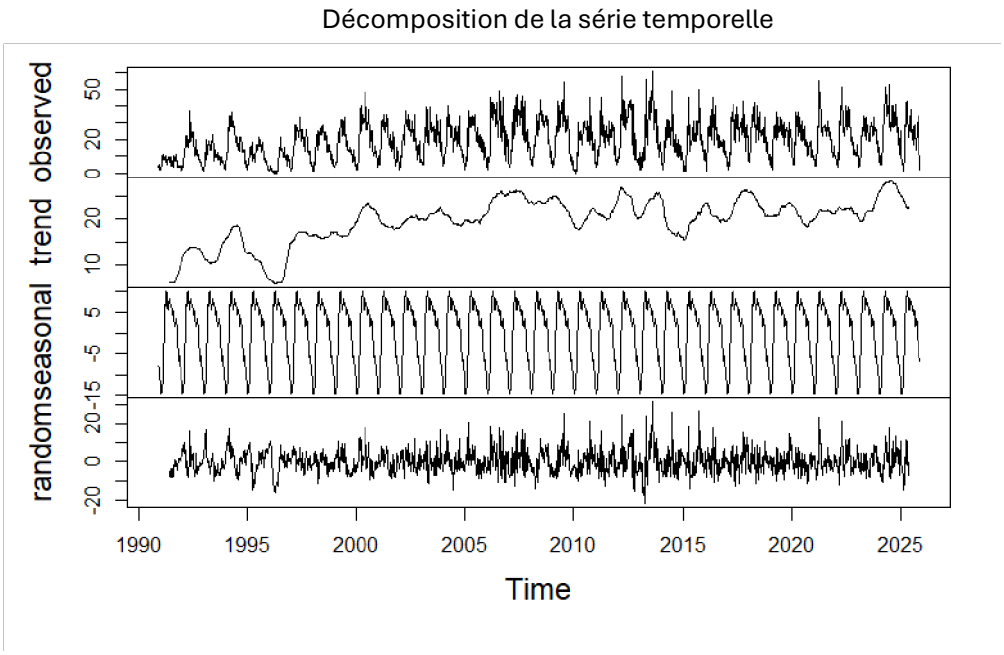

Les coefficients saisonniers moyens obtenus pour chaque semaine de l'année mettent en évidence un profil typique de la varicelle : des semaines de forte incidence (notamment en hiver et au début du printemps) alternant avec d'autres périodes plus faibles (en été). Cela montre que cet indicateur a une forte saisonnalité. Ce cycle saisonnier régulier est cohérent avec la littérature épidémiologique et confirme la nécessité de corriger la série pour les variations saisonnières afin d'analyser la tendance sous-jacente.

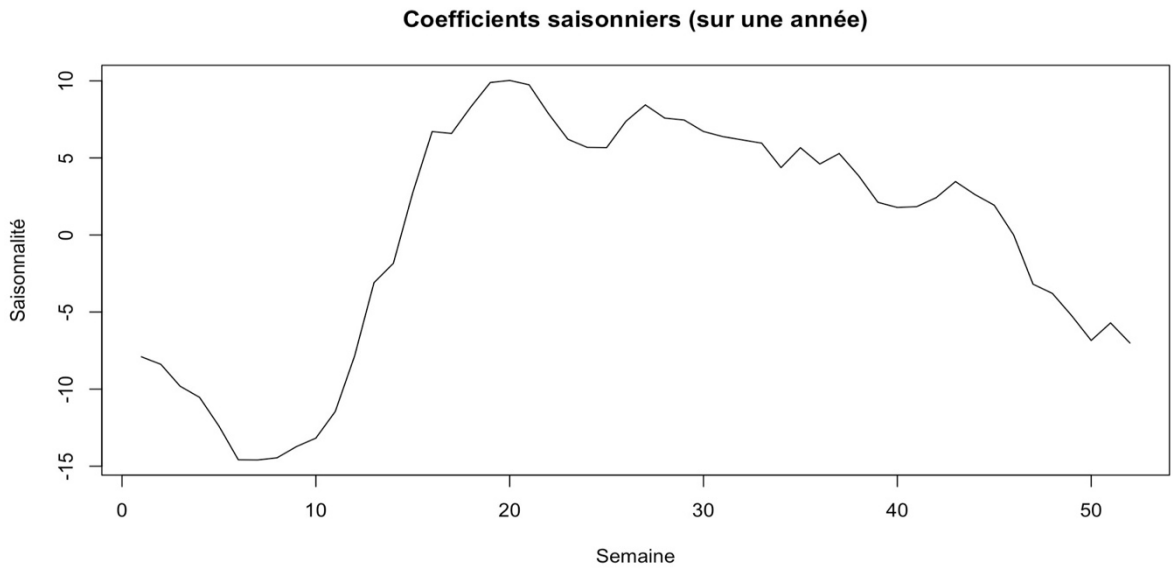

2.3 Désaisonnalisation et analyse des résidus

2.3.1 Série désaisonnalisée

En soustrayant la composante saisonnière de la série brute, on obtient la série corrigée des variations saisonnières (CVS). Cette nouvelle série permet de mieux observer la tendance de fond et les fluctuations irrégulières, en éliminant l'effet récurrent de la saisonnalité. En effet, le graphique de la CVS met en évidence les grandes tendances de l'incidence de la varicelle ainsi que les épisodes de hausse ou de baisse qui ne s'expliquent pas par la saisonnalité habituelle. Cela facilite l'interprétation des changements structurels de l'épidémie.

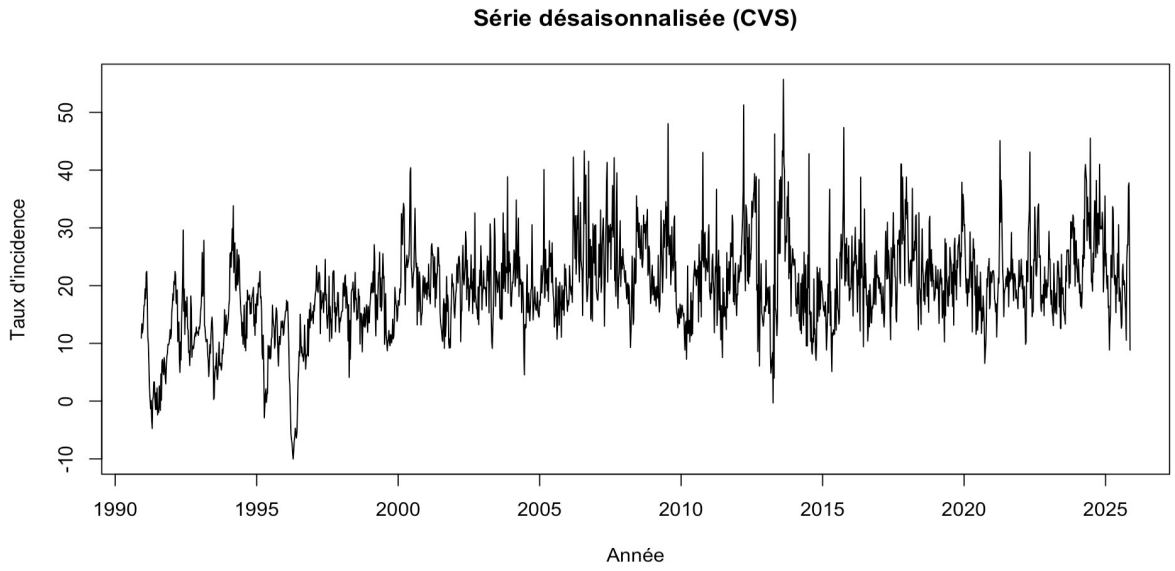

2.3.2 Analyse des résidus

Pour vérifier la présence d'éventuelles valeurs extrêmes « outliers », nous avons étudié les résidus issus de la décomposition (fonction *random*). Le boxplot montre que la plupart des résidus restent proches de zéro, avec quelques semaines présentant des valeurs atypiques en dehors des moustaches, correspondant à des épisodes d'incidence inhabituels. Cela indique que le modèle de décomposition est globalement satisfaisant.

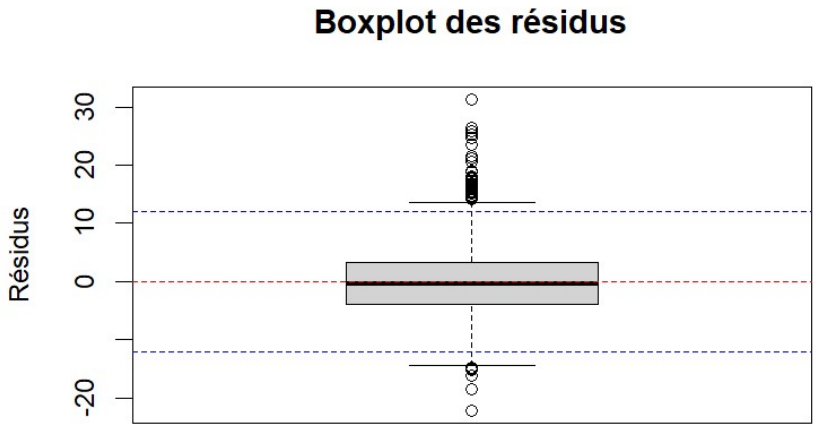

3. Prévisions du taux d'incidence de la varicelle

3.1 Prévision pour l'automne et l'hiver

Afin de prévoir l'évolution du taux d'incidence pour le reste de l'automne et le prochain hiver, trois modèles de prévision différents ont été utilisés. Ces approches reposent sur des principes distincts et permettent de comparer les résultats obtenus avant d'évaluer la qualité des prévisions.

3.1.1 Méthode polynomiale

La première méthode repose sur une approche en deux étapes. Dans un premier temps, la série est désaisonnalisée en soustrayant la composante saisonnière issue de la décomposition de la série, afin d'obtenir une série corrigée des variations saisonnières (CVS). Dans un second temps, la tendance de cette série CVS est modélisée à l'aide d'une régression polynomiale d'ordre 2, en fonction du temps, afin de capturer une éventuelle courbure dans l'évolution du taux d'incidence. La tendance estimée est ensuite extrapolée sur les 12 semaines suivantes, correspondant à la fin de l'année 2025. Enfin, la saisonnalité est réintroduite en appliquant le motif saisonnier observé, ce qui permet d'obtenir la prévision finale. Cette méthode combine ainsi une modélisation déterministe de la tendance et la répétition des effets saisonniers passés.

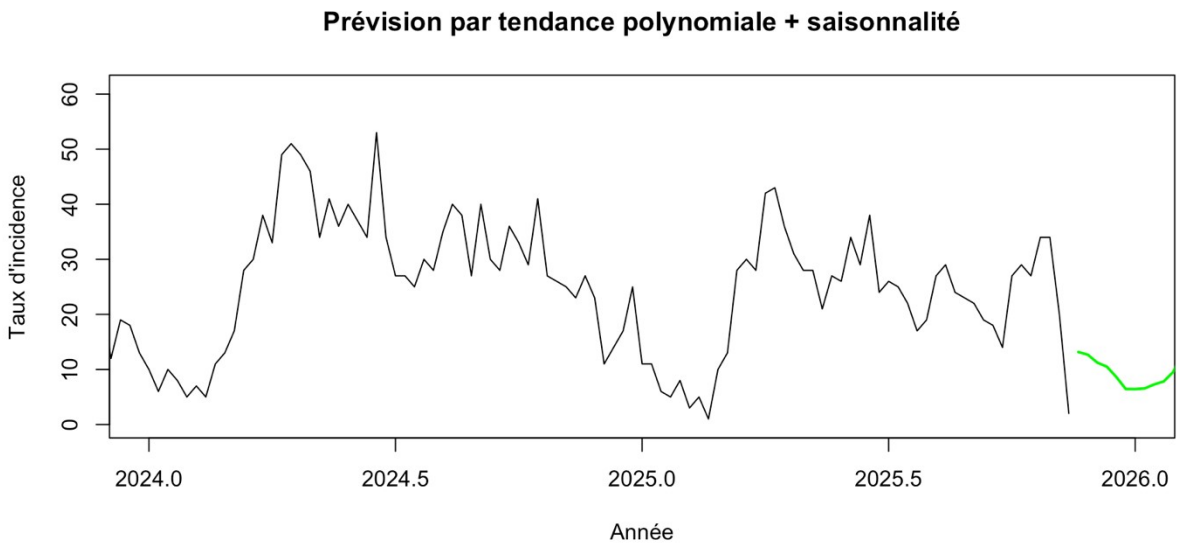

3.1.2 Méthode HW

La seconde méthode de prévision repose sur le lissage exponentiel de Holt-Winters, qui permet de modéliser simultanément la tendance, la saisonnalité et le niveau de la série temporelle. Le modèle est ajusté sur l'ensemble de la série du taux d'incidence à l'aide de la fonction *HoltWinters*, sans spécifier a priori le type de saisonnalité, celui-ci étant estimé automatiquement. Une fois le modèle calibré, une prévision est réalisée sur un horizon de 12 semaines, correspondant à la fin de l'année 2025. Les valeurs prédites sont ensuite représentées graphiquement et superposées à la série observée, ce qui permet de visualiser l'évolution attendue du taux d'incidence pour le reste de l'automne et le début de l'hiver.

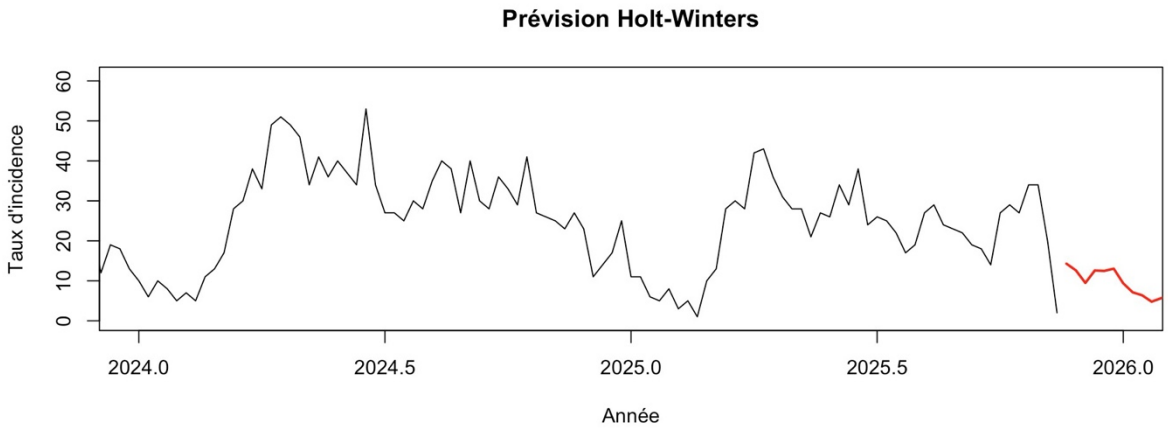

3.1.3 Méthode SARMA

La dernière approche utilise un modèle SARMA, obtenu par l'intermédiaire de la fonction *auto.arima*, qui sélectionne automatiquement le modèle ARIMA saisonnier le plus adapté aux données en se basant sur des critères d'information. Cette méthode modélise la dépendance temporelle de la série à travers ses composantes autorégressives, moyenne mobile et saisonnières. Une fois le modèle ajusté, une prévision sur un horizon de 12 semaines est produite à l'aide de la fonction *forecast*. Les valeurs prévues permettent d'anticiper l'évolution du taux d'incidence jusqu'à la fin de l'année 2025. La représentation graphique met en évidence la continuité entre les données observées et les prévisions issues du modèle SARMA.

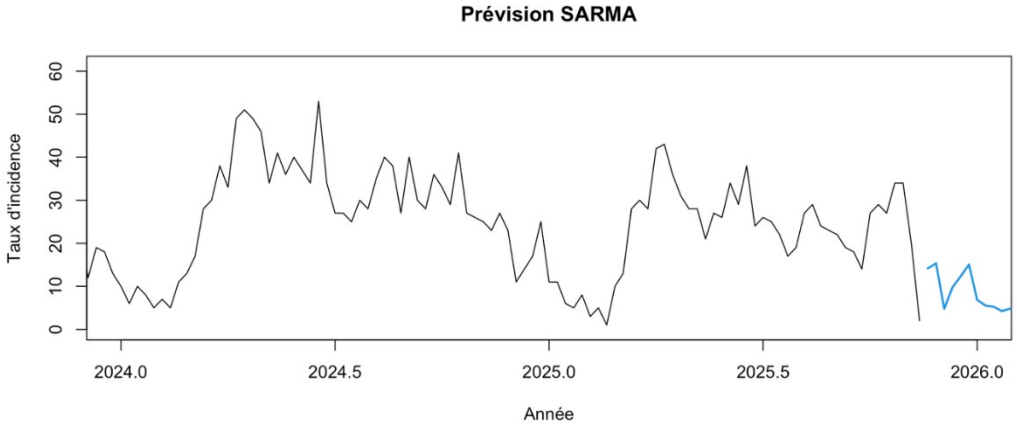

3.1.4 Comparaison des 3 modèles de prévision

Les graphiques de prévision montrent que les trois méthodes permettent de suivre globalement l'évolution de la série, mais avec des performances différentes selon la période. La prise en compte conjointe de la tendance et de la saisonnalité donne généralement de meilleures prévisions que les approches plus simples.

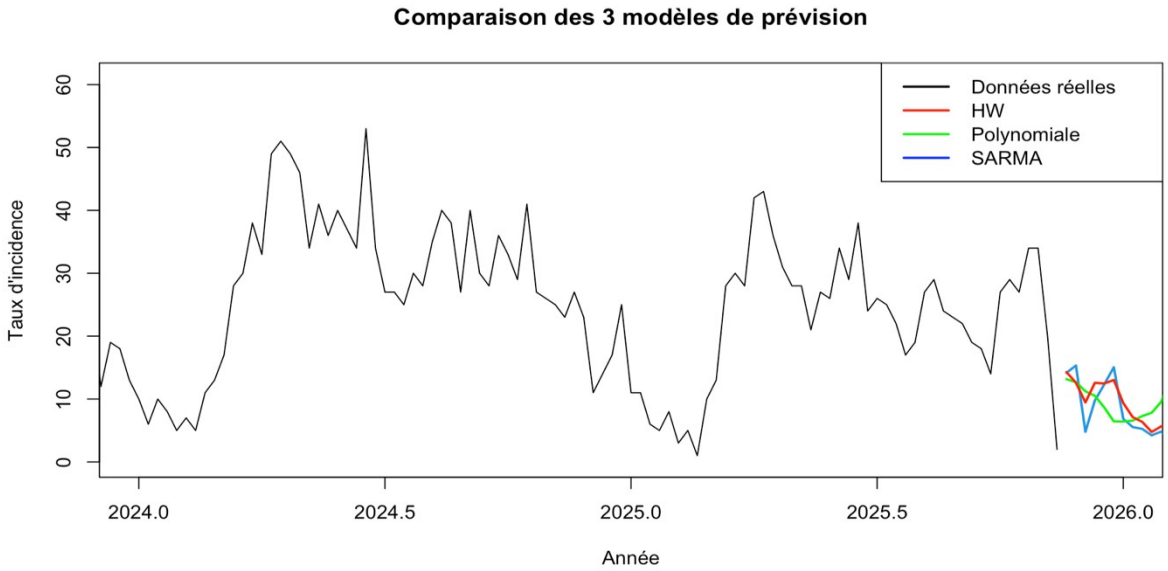

3.2 Évaluation de la qualité des prévisions

Afin d'évaluer la qualité des prévisions, les mêmes méthodes de modélisation que dans la partie précédente ont été réutilisées.

Dans un premier temps, la série temporelle du taux d'incidence est scindée en deux sous-ensembles afin d'évaluer la qualité des prévisions. Les données allant jusqu'à la semaine 52 de l'année 2024 sont utilisées comme jeu d'entraînement (*train*), tandis que les 40 premières semaines de l'année 2025 constituent le jeu de test (*test*). Cette séparation permet de reproduire une situation réaliste de prévision, où les valeurs futures sont inconnues au moment de l'estimation des modèles.

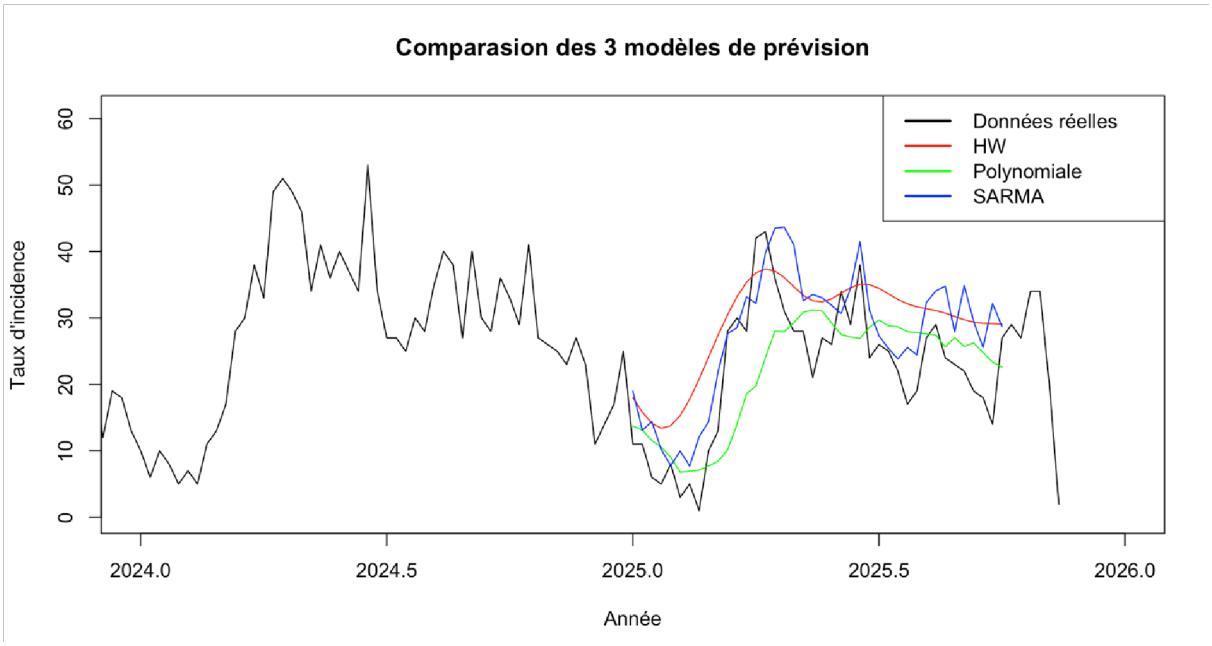

Dans un second temps, Pour chaque méthode, nous avons calculé l'erreur quadratique moyenne (EQM) entre les valeurs prédites et les valeurs observées (*test*). Cela nous a permis de comparer objectivement les performances : plus l'EQM est faible, meilleure est la méthode de prévision.

	Methode	EQM
1	SARMA	57.18886
2	Polynomial	64.78502
3	HW	81.40276

Les résultats montrent que la méthode SARMA est celle qui fournit les prévisions les plus précises, avec l'erreur quadratique moyenne la plus faible (57,19). Les résultats confirment que les approches fondées sur la modélisation de la dépendance temporelle et de la tendance sont les plus adaptées pour prévoir l'évolution du taux d'incidence dans ce contexte.

SUMMARY

This project focuses on the analysis and forecasting the weekly incidence rate of chickenpox in France using data from the Sentinelles network, covering the period from 1990 to 2025. The analysis highlights a strong seasonal pattern in the incidence rate, with peaks typically occurring in winter and early spring.

After decomposing the time series to separate trend, seasonality and residuals, a deseasonalized series (CVS) was produced to better identify underlying trends and irregular fluctuations. We identified outliers through a boxplot of residuals, indicating weeks with unusually high incidence. We used three forecasting methods: linear trend, polynomial trend and time regression. They were applied to predict the incidence for the remaining autumn and upcoming winter. We evaluated the quality of these forecasts using the mean squared error (MSE). Those showed that models accounting for both trend and seasonality generally provided more accurate predictions.

To sum up, this study demonstrates the value of time series analysis for epidemiological surveillance and public health planning.